
CAIM Sessió 1: Llei de Zipf i de Heaps

Ferriol Falip Torras i Martí Puerta Joves

1 Llei de Zipf

Aquesta llei estableix que, en un cos gran de text, la freqüència d'una paraula es inversament proporcional a la seva posició en l'ordre de freqüència.

$$f = \frac{c}{(rank + a)^b}$$

Per obtenir les paraules i les seves freqüències hem eliminat totes aquelles que contenen algun símbol especial que mai seria present en una paraula. D'aquesta manera hem eliminat una gran quantitat de soroll. Tot i això encara hi ha certs conjunts de caràcters que no son paraules que no han estat eliminats. Aquests però, no generen una distorsió notable visible en els resultats.

Un cop obtingudes les dades netes, hem fitat la corba de Zipf mitjançant la funció *curve_fit()* de la llibreria *scipy*, amb els diferents conjunts de textos.

Col·lecció	a	b	c
20 newsgroups	1.0069	1.8048	368330.3226
Novel·les	0.9845	2.2826	541413.9515
Arxiv abstracts	1.043	1.5967	1745145.0329

Taula 1: Valors dels paràmetres *a* *b* i *c* obtinguts segons la col·lecció

En conclusió, en els tres conjunts el valor de *a* es manté proper a 1, mentre que *b*, tot i que amb una mica més de variància sembla que volta al voltant de 2. També podem observar a la Figura 1 com per textos més massius i de temes diversos com son els abstracts d'*Arxiv* la cua de la gràfica cau més ràpidament al final seguint una *a* més propera a 2 mentre que analitzant només dues novel·les del mateix autor la cua segueix tenint una *a* propera a 1.




Figura 1: Representació gràfica de la fita de la cua de les dades per els abstracts d'*Arxiv* i les novel·les d'Edgar Allan Poe




Figura 2: Representació gràfica a escala logarítmica de les dades obtingudes de la col·lecció *20 newsgroups*




Figura 3: Representació gràfica a escala logarítmica de les dades obtingudes de la col·lecció de novel·les




Figura 4: Representació gràfica a escala logarítmica de les dades obtingudes de la col·lecció d'abstracts extrets d'*Arxiv*

2 Llei de Heaps

Aquesta llei relaciona el nombre creixent de paraules amb el text amb el també creixent (però de manera sublineal) de paraules diferents que apareixen al text. Sigui n la mida del text, $d(n)$ el nombre de paraules diferents i els paràmetres k i β que depenen del text la llei és la següent:

$$d(n) = k * n^\beta$$

Per obtenir les parelles de paraules diferents i número total de paraules hem creat un script que, per ordre alfabètic dels noms dels fitxers, agafa una novel·la, n'obté la parella de número de paraules i paraules diferents i torna a fer el mateix afegint la següent novel·la. Aquest procés continua fins haver afegit totes les novel·les i haver obtingut els punts necessaris per a realitzar l'estudi.

Es preté observar que el número de paraules diferents s'ajusta a la corba definida per la llei.

Col·lecció	k	β
Novel·les	5.1077	0.6260

Taula 2: Valors dels paràmetres k i β obtinguts




Figura 5: Representació gràfica en escala normal i logarítmica de les dades obtingudes

En conclusió, els resultats dels paràmetres obtinguts ens indiquen que el valor de k suggereix que el vocabulari creix de forma poc significativa a l'inici. Una k més aviat gran tendeix a indicar que amb poca quantitat de paraules es troben moltes paraules noves. A Per altre banda, el valor de β suggereix que el nombre de paraules diferents creix força en relació al creixement del nombre de paraules. Al realitzar una recerca ràpida sobre la llei de Heaps hem trobat que el valor de β acostuma a estar entre 0.4 i 0.6, que estigui lleugerament per sobre és segurament degut a que la rigorositat amb la qual s'han eliminat paraules en fer el tractament no ha estat molt alta i per tant hi ha soroll a les dades que distorsiona lleugerament el resultats..