

CAIM Sessió 3: Rocchio

Ferriol Falip Torras i Martí Puerta Juvés

17/10/2024

1 Introducció

L'objectiu d'aquesta sessió és utilitzar la regla de Rocchio per implementar un cerca a partir d'una consulta donada per l'usuari amb *relevance feedback*. En concret volem treballar amb els paràmetres *alpha* i *beta* de la regla de Rocchio, el nombre de rondes que es fa *relevance feedback* (*nrounds*), la quantitat de documents que tenim en compte (*k*) i la mida de la query (*R*).

$$q' = \alpha * q + \beta * \frac{d_1 + d_2 + \dots + d_k}{k}$$

Per implementar-ho hem seguit l'estructura de *SearchIndexWeights.py*. Bàsicament, el procés consisteix en utilitzar la funció de la sessió anterior *toTFIDF*, adaptada per treballar amb diccionaris, amb els *k* documents que obtenim de buscar amb la query *q*. Tot seguit obtenim dos diccionaris, un diccionari que conté els termes i pesos dels *k* documents més rellevants i un altre que conté els termes de la query *q*. Seguint la regla de Rocchio multipliquem per *alpha* i *beta* els diccionaris corresponents i els sumem, obtenint un nou diccionari del qual extreurem els *R* termes més rellevants i els utilitzarem per generar la nova query *q'*. Repetim aquest procés *nrounds* vegades i obtenim el resultat final.

Seguint el funcionament de *SearchIndexWeights.py* hem implementat el parser per tal de poder-li passar els paràmetres amb els valors desitjats. A continuació es mostra un exemple:

```
$ python3 RocchioParser.py --index [--nhits] [--rounds] [--alpha] [--beta] [--qsize] --query
```


On només són obligatoris els paràmetres *index* i *query*.

2 Experimentació

En primer lloc, establim una query arbitrària amb la qual treballarem: *technology hardware*. D'aquesta manera anirem experimentant amb els diferents paràmetres per investigar l'efecte de cada un i trobar, si és possible, un valor o rang de valors òptim.

Experiment 1: Valor de *alpha* elevat, valor de *beta* baix:

- Paràmetres: *nrounds* = 5, *alpha* = 0.9, *beta* = 0.1, *k* = 5, *R* = 5



```
CAIM/Lab3> python3 RocchioParser.py --index news --rounds 5 --alpha 0.9 --beta 0.1 --qsize 5 --query technology hardware
['technology', 'hardware']
['technology^0.6491454959349765', 'hardware^0.6475870573725419', 'pc^0.01081079079456529', 'disks^0.010594166515742217', 'powerpc^0.009069086368780075']
['hardware^0.637643232359509', 'technology^0.6371053918837981', 'pc^0.012916366948743378', 'disks^0.01064820084539948', 'powerpc^0.010386691063628594']
['hardware^0.6386426371850439', 'technology^0.6360385276237437', 'pc^0.015200600913135322', 'powerpc^0.011854966099012317', 'disks^0.010880876096127902']
['hardware^0.639632762095298', 'technology^0.6349660780976924', 'pc^0.01748060573717716', 'powerpc^0.013320498197851355', 'disks^0.011113010849513867']
['hardware^0.6406136273062115', 'technology^0.6338881049974541', 'pc^0.019756336052495518', 'powerpc^0.014783258330093228', 'disks^0.01134460107591448']
1 documents trobats, es mostren els 5 millors:
ID= lGR3DJMBwnsnK5-SI3EJ SCORE= 16.653072
PATH= ./20_newsgroups/comp.sys.mac.hardware/0004532
TEXT= {Send follow ups to comp.sys.mac.advocacy. Sorry a
-----
CAIM/Lab3>
```

Figura 1: Resultats de l'experiment 1

En aquest experiment podem observar que el pes més gran està concentrat en les paraules de la query inicial, tot i això, podem observar com s'ha afegit altres paraules relacionades a les queries pc, disks, powerpc.

També podem observar que com que li assignem molt pes a la query inicial i tan poc a les paraules que trobem, un cop s'ha omplert la dimensió de la query, aquesta ja no varia. (A la segona iteració ja tenim 5 termes i aquests ja no varien).

Experiment 2: Valor de *alpha* baix, Valor de *beta* elevat:

- Paràmetres: *nrounds* = 5, α = 0.1, β = 0.9, *k* = 5, *R* = 5




Figura 2: Resultats de l'experiment 2

Ara podem observar com a cada iteració el pes de les paraules va canviant fins a obtenir una query final bastant diferent de la inicial (*32*, *os*, *scsi*, *hardware*, *pc*), havent desaparegut el terme *technology*, i *hardware* havent perdut molt del pes que tenia a la primera query. Els termes, però segueixen estant estretament relacionats amb els de la query inicial.

Experiment 3: Valor de *alpha* i *beta* equilibrats:

- Paràmetres: *nrounds* = 5, α = 0.5, β = 0.5, *k* = 5, *R* = 5




Figura 3: Resultats de l'experiment 3

En aquest experiment hem obtingut la mateixa query resultant que en el primer experiment, ara però amb uns pesos molt més equilibrats.

Experiment 4: Rebaixem el nombre d'iteracions (*nrounds*) d'aplicació de Rocchio

- Paràmetres: *nrounds* = 2, α = 0.5, β = 0.5, *k* = 5, *R* = 5

Els resultats obtinguts ens mostren com la query resultant varia molt poc de la inicial. Això és normal, ja que a l'aplicar Rocchio menys vegades, menys vegades podem variar els pesos. Fins i tot en donar molt més pes als termes dels textos, obtenim que els termes de la query inicial són els més rellevants.

```
LXTerminal
Fitxer  Edita  Pestanyes  Ajuda
* LXTerminal  LXTerminal
CAIM/lab3> python3 RocchioParser.py --index news --rounds 5 --alpha 0.9 --beta 0.1 --qsize 5 --query technology hardware
['technology', 'hardware']
['technology^0.6491454959349765', 'hardware^0.6475870573725419', 'pc^0.01081079079456529', 'disks^0.010594166515742217', 'powerpc^0.009069086368780075']
['hardware^0.637643232359509', 'technology^0.6371053918837981', 'pc^0.012916366948743378', 'disks^0.01064820084539948', 'powerpc^0.010386691063628594']
['hardware^0.6386426371850439', 'technology^0.6360385276237437', 'pc^0.015200600913135322', 'powerpc^0.011854966099012317', 'disks^0.010880876096127902']
['hardware^0.639632762095298', 'technology^0.6349660780076924', 'pc^0.01748060573717716', 'powerpc^0.013320498197851355', 'disks^0.011113010849513867']
['hardware^0.6406136273062115', 'technology^0.6338881049974541', 'pc^0.019756336052495518', 'powerpc^0.014783258330093228', 'disks^0.01134460107591448']
1 documents trobats, es mostren els 5 millors:
ID= lGR3DJMBwnsK5-SI3EJ SCORE= 16.653072
PATH= ./20_newsgroups/comp.sys.mac.hardware/0004532
TEXT= {Send follow ups to comp.sys.mac.advocacy. Sorry a
-----
CAIM/lab3>
```

Figura 4: Resultats experiment 4

Experiment 5: Augmentem el nombre d’iteracions d’aplicació de Rocchio

- Paràmetres: $nrounds = 10$, $\alpha = 0.5$, $\beta = 0.5$, $k = 5$, $R = 5$

```
LXTerminal
Fitxer  Edita  Pestanyes  Ajuda
LXTerminal  * LXTerminal
CAIM/lab3> python3 RocchioParser.py --index news --rounds 10 --alpha 0.5 --beta 0.5 --qsize 5 --query technology hardware
['technology', 'hardware']
['technology^0.41730035492869244', 'hardware^0.4095081621165193', 'pc^0.05405395397282644', 'disks^0.05297083257871108', 'powerpc^0.04534543184390037']
['hardware^0.35693579528855235', 'technology^0.35318885977042275', 'pc^0.05724440613789734', 'disks^0.04605060142256054', 'powerpc^0.04577814484960747']
['hardware^0.36089817529520724', 'technology^0.346885336173145', 'pc^0.0677074825956435', 'powerpc^0.05235384619256494', 'disks^0.04644551728531618']
['hardware^0.36449982478502607', 'technology^0.3404245568684602', 'pc^0.0779207611446106', 'powerpc^0.05876477683325463', 'disks^0.046796164375713635']
['hardware^0.36775352690133556', 'technology^0.33383069979736874', 'pc^0.08787521762515406', 'powerpc^0.06500573903911146', 'disks^0.047104322979287364']
['hardware^0.3706728833038878', 'technology^0.32712708228490994', 'pc^0.097563555044325', 'powerpc^0.07107262535296757', 'disks^0.04737186009840329']
['hardware^0.37327214129134983', 'technology^0.32033605918789704', 'pc^0.10698012160850262', 'powerpc^0.07696236293237654', 'disks^0.04760070779008836']
['hardware^0.3755660302888109', 'technology^0.3134789276946311', 'pc^0.11612081803126482', 'powerpc^0.08267285154132578', 'disks^0.047792842856788455']
['hardware^0.377569609196511', 'technology^0.30657585562948986', 'pc^0.1249829967715138', 'powerpc^0.08820289688075678', 'disks^0.047950268054443614']
['hardware^0.3792981256796657', 'technology^0.2996458293762678', 'pc^0.13356535572026443', 'powerpc^0.09355214081995425', 'disks^0.048074994929916987']
1 documents trobats, es mostren els 5 millors:
ID= MVIDDZMBnrNEr6v2ECBg SCORE= 26.12816
PATH= ./20_newsgroups/comp.sys.mac.hardware/0004532
TEXT= {Send follow ups to comp.sys.mac.advocacy. Sorry a
-----
Active
```

Figura 5: Resultats experiment 5

Podem observar que a partir de la 3 ronda d’aplicar Rocchio els canvis en els pesos dels termes és marginal, tant amb un pes d’alpha i beta equilibrat com amb un pes major en beta. (conclusió, aplicar roocchio moltes vegades no té gaire sentit)

Experiment 6: Rebaixem el nombre de termes de la query (R)

- Paràmetres: $nrounds = 5$, $\alpha = 0.5$, $\beta = 0.5$, $k = 5$, $R = 1$

Hem obtingut que el terme no varia i en cercar documents amb només una paraula obtenim un total de documents rellevants molt més alt.




Figura 6: Resultats experiment 6

Experiment 7: Rebaixem el nombre de documents rellevants (R)

- Paràmetres: $nrounds = 3$, $\alpha = 0.5$, $\beta = 0.5$, $k = 2$, $R = 2$




Figura 7: Resultats experiment 7

Experiment 8: Augmentem el nombre de documents rellevants (k)

- Paràmetres: $nrounds = 3$, $\alpha = 0.5$, $\beta = 0.5$, $k = 20$, $R = 2$




Figura 8: Resultats experiment 8

Podem observar com entre l'experiment 7 i 8 la consulta no ha variat i que el primer document extret és el mateix que en l'experiment anterior.

3 Conclusions

El nombre de rondes indica quantes vegades apliquem la regla de Rocchio. Hem descobert que, a partir de la ronda 3, els pesos varien de manera marginal.

Quan alfa és alt en relació amb beta, la consulta tendeix a mantenir-se igual; però quan beta és més alt que alfa, la consulta canvia molt. Això ens indica que, si volem preservar la consulta de l'usuari, hauríem d'assignar un valor d'alfa més alt; en canvi, si volem crear consultes amb paraules més rellevants relacionades amb els documents, hauríem d'assignar un valor de beta més alt.

La puntuació obtinguda pels documents està altament correlacionada amb els paràmetres alfa i beta.

R limita la mida màxima de la consulta a cada iteració; amb un R baix es troben més documents, mentre que amb un R alt se'n troben menys. Quan R és més alt, obtenim una major precisió, ja que la consulta és més complexa.

Respecte al paràmetre k, no hem pogut observar que la seva variació afecti de manera significativa al resultat. Segons la definició de recall (relevant docs retrieved/total relevant docs), si augmentem k també augmentem el recall. Això ens podria arribar a indicar que el recall no és massa significatiu.

L'únic paràmetre pel qual hem sigut capaços de trobar un valor òptim és per nRounds, ja que hem comprovat que a partir de 3 el resultat varia marginalment i no val la pena gastar recursos en realitzar més iteracions. En referència als altres paràmetres, trobar un òptim esdevé una tasca molt complexa, ja que depèn molt de la intenció de l'usuari quan realitza la consulta (si vol que les seves paraules apareguin, si vol molts documents per consultar o no...)