
CAIM Sessió 4: Pagerank

Ferriol Falip Torras i Martí Puerta Juvés

21/11/2024

1 Introducció

En aquesta pràctica hem d'aplicar el power method de l'algorisme de Pagerank en una xarxa de vols i aeroports per tal de calcular la importància d'aquests aeroports dins d'aquesta xarxa.

El càlcul de Pagerank en aquesta xarxa difereix lleugerament del càlcul que normalment realitzem. En aquest cas la importància d'un aeroport es calcula a partir dels vols (arestes) que arriben a ell, el pes d'aquests vols (número de vegades que es fa aquest vol) i la importància dels aeroports de sortida dels vols + un factor de teletransport (damping factor). Així doncs, sent w_{ij} el nombre de vols de i a j i s_j el *outweight* de j , tenim:

$$p_i = \sum_{i \rightarrow j} p_j * \frac{w_{ij}}{s_j} + \frac{1 - \lambda}{n}$$

2 Implementació

Al llegir el routes.txt, actualitzem el diccionari de routes que arriben a cada aeroport, això ens permetrà realitzar el càlcul de pagerank de manera eficient.

Per calcular els pageRanks, inicialment:

- Inicialitzem un vector P de mida n (mida del diccionari d'aeroports) amb un pes de $\frac{1}{n}$ a cada element.
- Assignem un damping factor $0 \leq \lambda \leq 1$.
- Assignem un treshold de convergència de $1 * 10^{-8}$
- Assignem un màxim d'iteracions per limitar el temps de computació
- Inicialitzem un iterador a 0.

Ara en un bucle que repetirem tants cops com màximes iteracions o bé fins que la màxima diferència entre vectors sigui més petita que el treshold, realitzem el següent:

- Iniciem un vector de mida n amb un pes de 0 a cada element
- Per cada aeroport iniciem un sumatori a 0 i mirem el seu diccionari de vols incidents, per cada vol calculem el pes que aporta ($rankSum += P[j] * \frac{edge.weight}{outWeight}$). Finalment, multipliquem el resultat pel damping factor i sumem el teleportation factor $\frac{1-\lambda}{n}$.
- Normalitzem el vector resultant per obtenir que la suma de tots els pageranks = 1, ja que en perdre diferents vols a l'hora de llegir les rutes per les restriccions de l'enunciat, el sumatori de pageranks donava al volant de 0.6. Hem decidit normalitzar, ja que és un mètode ràpid que conserva la importància de cada un dels aeroports (si era important ho continua sent, si no ho era no ho continua sent).
- Assignem aquest nou vector Q a P .
- Finalment comprovem que la diferència entre el vector anterior i actual i, en cas que sigui més petita que el treshold voldrà dir que els pageranks han convergit i que podem acabar. Altrament seguirem executant el bucle.

3 Resultats i conclusions

A continuació anem a jugar una mica amb el dumping factor. Per diferents valors mirarem a veure com varien els resultats dels pageranks dels 10 aeroports més importants i el temps que tarda a convergir.

$\lambda = 0.25$

```
DEN 0.0017825320540995819
DME 0.0015549465281393423
ORD 0.001510608066385193
DFW 0.0013853116844950498
SYD 0.0013552792462352436
ATL 0.001339052054076664
BOG 0.0013260266912207127
LAX 0.0012368703636958336
AEP 0.0012344382114991028
MEX 0.0011557870801295902
```

```
-----
#Iterations: 12
Time of computePageRanks(): 0.17616033554077148
```

$\lambda = 0.5$

```
DEN    0.003571672954327232
ORD    0.003198981247102415
LAX    0.0029345572596774228
DME    0.00279966984176208
SYD    0.002712714342561858
ATL    0.00265815474392162
DFW    0.002605221494444179
BOG    0.0024298258511346207
PEK    0.0022604960440513913
AEP    0.0021634008237311026
-----
#Iterations: 24
Time of computePageRanks(): 0.41785240173339844
```

$\lambda = 0.75$

```
DEN    0.005347473009886365
ORD    0.005294410113593144
LAX    0.005263686822897595
ATL    0.004094950797178206
LHR    0.004030802207560538
SIN    0.0039636933026085015
PEK    0.0039407249236109625
CDG    0.003913876545225532
SYD    0.0038721109246365134
FRA    0.003812276761665374
-----
#Iterations: 62
Time of computePageRanks(): 1.0385589599609375
```

$\lambda = 0.85$

```
LAX    0.006270439008410624
ORD    0.006254627620526724
DEN    0.006014271914813745
LHR    0.005126131745386143
CDG    0.004950856178348413
PEK    0.004888706966343569
FRA    0.004830707717744423
SIN    0.004728277829111717
ATL    0.004715023590895361
JFK    0.004465655899113393
-----
#Iterations: 114
Time of computePageRanks(): 1.86027193069458
```

$\lambda = 0.95$

```
ORD    0.007282728932564862
LAX    0.007182888319318274
DEN    0.006599034201794595
LHR    0.006448267718587567
PEK    0.006317309333997146
CDG    0.006278776161303422
FRA    0.006157314457883594
AMS    0.005667296905331745
JFK    0.00550040776742181
SIN    0.0053907982178766954
-----
#Iterations: 390
Time of computePageRanks(): 7.200664758682251
```

En conclusió, podem observar com un dumping factor més elevat incrementa el nombre d'iteracions necessàries per convergir i conseqüentment el temps d'execució, però obté valors més diferenciats entre els aeroports més importats i menys importats, és a dir, els aeroports més importats obtenen valors més elevats mentre que els menys importats obtenen velors més petits. En el fitxer *resultats.txt* es poden observar els resultats complets d'una execució del codi amb un dumping factor de 0.85.